

유전자원보호구역 관보고시 DB 구축

전처리 품질 분석 보고서

2026년 6월

1. 개요

산림청 산하 5개 지방산림청의 산림유전자원보호구역 관련 관보고시 PDF 344건을 처리하여 PostgreSQL DB에 적재하였다. 총 1,471개 필지 행이 생성되었으며, Claude API를 활용한 비정형 PDF 파싱 방식으로 인해 고시별 컬럼 구조의 차이가 존재한다. 본 보고서는 적재 결과의 품질을 분석하고 후속 전처리 방향을 제시한다.

항목	값
처리 PDF 수	344건
총 필지 수	1,471행
테이블 컬럼 수	204개
기본 설계 컬럼 수	19개
동적 추가 컬럼 수	185개

2. 컬럼 현황

2.1 기본 컬럼 null 비율

19개 기본 컬럼의 데이터 총전율이다. 해제사유·잔여면적·임반 등은 고시 유형에 따라 구조적으로 존재하지 않는 필드이므로 데이터 손실과 구분이 필요하다.

컬럼명	유효값 수	null 비율
번호	1471	0.0%
파일명	1471	0.0%
지방산립청	1471	0.0%
고시번호	1471	0.0%
유형	1471	0.0%
고시날짜	1441	2.0%
소재지	1377	6.4%
지번	1289	12.4%
임반	99	93.3%
지목	1116	24.1%
소유자	1062	27.8%
지적	1100	25.2%
지정면적	1143	22.3%
해제면적	420	71.4%
잔여면적	94	93.6%
지정유형	1441	2.0%
해제사유	384	73.9%
명칭	965	34.4%
비고	407	72.3%

2.2 동적 추가 컬럼 현황

고시별 표 구조 차이로 인해 파싱 중 동적으로 추가된 컬럼들이다. 대부분 특정 소수 고시에서만 나타나는 필드로 null 비율이 매우 높다.

컬럼명	유효값 수	총전율
구분	126	8.6%
시도	26	1.8%

컬럼명	유효값 수	총전율
시군	29	2.0%
읍면	29	2.0%
리동	26	1.8%
위치	4	0.3%
산림유전자원보호림번호	4	0.3%
보호대상수종	4	0.3%
지정기간	1	0.1%
관리소	17	1.2%
연번	333	22.6%
세부유형	14	1.0%
정정사유	28	1.9%
경도	26	1.8%
위도	26	1.8%

3. 주요 컬럼 품질 분석

3.1 유형 컬럼

현재 유형 컬럼에 123개의 distinct 값이 존재한다. 동일한 고시 유형이 파일명 표기 방식·띄어쓰기·괄호 종류 차이 등으로 다양하게 기록되어 정규화가 필요하다.

유형 값 (상위 10)	건수
산림유전자원보호구역(자연생태계보전지역) 제3종 수원함양보호구역	103
산림유전자원보호구역(산림유전자원보호구역) 제3종 수원함양보호구역	101
산림유전자원보호구역 제3종 수원함양보호구역	80
산림유전자원보호구역 제3종 수원함양보호구역 제3종 수원함양보호구역	80
산림유전자원보호구역 제3종 수원함양보호구역 제3종 수원함양보호구역	77
산림유전자원보호구역(산림유전자원보호구역) 제3종 수원함양보호구역	71
산림유전자원보호구역(산림유전자원보호구역) 제3종 수원함양보호구역	69
산림유전자원보호구역 제3종 수원함양보호구역 제3종 수원함양보호구역	63
산림유전자원보호구역 제3종 수원함양보호구역 제3종 수원함양보호구역	47
지정	34

3.2 지정유형 컬럼

필지별 보호구역 유형을 나타내는 핵심 컬럼이다. 41개 distinct 값이 존재하며, 한 고시 안에 여러 보호구역 유형이 혼재하는 경우가 있어 필지 단위 분류에 활용된다.

지정유형 (상위 10)	건수
산림유전자원보호구역	820
산림유전자원보호림	307
제3종 수원함양보호구역	80
산림유전자원보호구역(자연생태계보전지역)	45
제1종 수원함양보호구역	24
희귀식물자생지	23
자연생태계보전지역	17
산림유전자원보호구역(고산식물지대)	14
희귀식물 자생지 등	13

지정유형 (상위 10)	건수
산림유전자원보호구역 (자연생태계보전지역)	13

3.3 지방산림청 컬럼

2001~2005년대 구명칭(지방산림관리청)과 현행명칭(지방산림청)이 혼재한다. 또한 일부 행에서 NULL이 추출되어 파일명 기반 보완이 필요하다.

지방산림청	건수
북부지방산림청	475
남부지방산림청	248
서부지방산림청	220
동부지방산림청	199
(NULL)	147
중부지방산림청	89
남부지방산림관리청	45
북부지방산림관리청	25
동부지방산림관리청	10
중부지방산림관리청	7
서부지방산림관리청	6

3.4 유전자원보호구역_여부 컬럼

지정유형 컬럼 기반으로 필지 단위 판별하여 업데이트 완료하였다. “유전자원” 포함 여부로 True/False를 결정하며, null은 지정유형이 추출되지 않은 케이스이다.

값	건수
True (유전자원보호구역)	1233
False (기타 보호구역)	238
NULL (지정유형 미추출)	0

4. 데이터 형식 통일관성

4.1 고시날짜

6가지 날짜 형식이 혼재한다. DATE 타입으로 통합하거나 표준 형식으로 정규화가 필요하다.

날짜 형식 패턴	건수
기타	1441

4.2 면적 컬럼 (지정면적·해제면적·잔여면적)

대부분 단위 없이 순수 숫자로 기록되어 있으며, 일부는 m^2 또는 ha를 명시한다. 숫자 변환 전 콤마 제거, 단위 분리, $ha \rightarrow m^2$ 변환 처리가 필요하다.

면적값 유형	건수
기타	1124
NULL	328
m^2 명시	12
ha 명시	7

4.3 소재지

광역시도 포함 여부가 일관되지 않는다. 시도명 미포함 건은 지방산림청 관할 지역 매핑 또는 주소 정규화 API를 통해 표준화할 수 있다.

소재지 패턴	건수
시도 미포함	717
시도 포함	660
NULL	94

4.4 지번

“산 217”처럼 산과 숫자 사이 공백이 포함된 케이스가 일부 존재한다. GIS 연계 시 공백 제거 등 정규화가 필요하다.

지번 패턴	건수
기타	1289
NULL	182

5. 전처리 방향 및 우선순위

우선순위	항목	상세
P1	고시날짜 표준화	6가지 혼재 패턴 → DATE 타입으로 변환. 정규식 파싱 후 별도 date 컬럼 추가
P1	유형 컬럼 정규화	123개 → 지정/해제/정정/변경/공고 5개 범주로 통합
P2	면적 컬럼 숫자 변환	콤마 제거, 단위 분리 (㎡/ha), ha→㎡ 변환 후 NUMERIC 컬럼으로 별도 저장. 원본 유지
P2	소재지 시도 보완	시도 미포함 건(약 48%)에 지방산림청 관할 지역 매핑 또는 주소 API 표준화
P2	지방산림청 구명칭 통합	~관리청 → ~청 으로 정규화 (원본 컬럼은 유지)
P3	지번 공백 정규화	"산 217" → "산217" 형식으로 통일
P3	희박 동적 컬럼 처리	null 비율 95% 이상 컬럼 활용 여부 결정. 필요 시 부가정보 테이블로 분리
P3	raw_text 활용	필지 추출 누락 의심 건 재파싱 소스로 활용. 평균 3,013자 원문 100% 보존 중

6. raw_text 보존 현황

pdfplumber로 추출한 원문 텍스트를 전체 1,471건에 대해 보존하고 있다. 향후 파싱 결과 오류 수정, 추가 필드 재추출 등에 재활용 가능하다.

통계 항목	값
보존 건수	1,471건 (100%)
최소 길이	384자
최대 길이	186,953자
평균 길이	3,351자
중앙값 길이	1,841자